KHALOUFI YOUSSEF

Étudiant M2 IA & Sciences des Données | Data Engineering

Stage de fin d'études Data Engineering – 6 mois – à partir de février 2027

Tanger, Maroc | +212 777 442 163 | youssefkhaloufi43@gmail.com | Portfolio | LinkedIn | GitHub

PROFIL

Étudiant en M2 IA & Sciences des Données, orienté Data Engineering. Expérience pratique de la conception de pipelines de données batch et streaming : ingestion, transformation, modélisation et orchestration avec SQL, Python, dbt, Airflow, PySpark et Kafka.
À la recherche d'un stage de fin d'études de 6 mois à partir de février 2027.

COMPÉTENCES TECHNIQUES

Langages	Python, SQL
Données & stockage	PostgreSQL, DuckDB, MongoDB, Parquet
Data Engineering	dbt, ETL/ELT, Airflow, PySpark, Spark Structured Streaming
Cloud	Azure (en cours d'apprentissage)
Outils & écosystème	Kafka, Docker/Compose, Git/GitHub, GitHub Actions, pytest

EXPÉRIENCE

Juil.–août 2026 *Tanger, Maroc*

Stage académique en Data Engineering – FST Tanger

Mobility Control Tower

github.com/KYoussefAI/Mobility_Control_Tower

• Conception d'un pipeline GTFS / GTFS-Realtime (Raw → Bronze → Silver → dbt → DuckDB) avec hachage SHA-256, traçabilité des données et snapshots idempotents.

• Développement de 17 modèles dbt (8 staging, 3 intermédiaires, 6 marts) et de tests de qualité sur la couverture temps réel, la ponctualité, la fraîcheur et les retards.

• Orchestration via 2 DAGs Airflow (batch quotidien, temps réel toutes les 5 min) ; intégration continue avec couverture de tests Python ≥ 80 %.

PROJETS

HydroWatch – Pipeline ELT & Data Warehouse analytique

Python | PostgreSQL | Docker | dbt | SQL

• Conception d'un pipeline ELT sur des données hydrologiques USGS : ingestion Python robuste, stockage RAW rejouable et transformations dbt vers PostgreSQL.

• Modélisation dimensionnelle en étoile, chargements incrémentaux idempotents, historisation SCD Type 2, contrôles qualité et marts analytiques.

Amazon Reviews Streaming Sentiment Pipeline – FST Tanger

github.com/KYoussefAI/amazon-reviews-streaming-pipeline

• Mise en place d'un pipeline Kafka → Spark Structured Streaming → MongoDB pour l'inférence et la persistance en continu ; orchestration batch avec Airflow et conteneurisation avec Docker Compose.

• Comparaison de 5 modèles Spark MLlib sur des avis préparés avec PySpark ; meilleur score Macro F1 : 0,701.

FORMATION

2025 – 2027 **Master en Sciences et Techniques – Intelligence Artificielle et Sciences de Données**
Université Abdelmalek Essaâdi – Faculté des Sciences et Techniques de Tanger (FSTT)

2024 – 2025 **Licence en Sciences et Techniques – Statistique et Science des Données**
Université Abdelmalek Essaâdi – Faculté des Sciences et Techniques de Tanger (FSTT)

LANGUES

Arabe : langue maternelle | Anglais : C1 | Français : B2